

Qualidade de vinhos com Machine Learning

Utilizando marcadores químicos
para classificação e triagem



Este documento é resultado de um trabalho desenvolvido no âmbito da pós-graduação em Data Analytics da FIAP, como requisito para a conclusão da Fase 2 do Tech Challenge.

Participantes:

- Alexandre Araújo da Costa
- Douglas da Silva Souto
- Erick Vinnycius Jeremias de Oliveira
- João Pedro Henriques Machado
- Lucas Freitas Chaves

Repositório:

https://github.com/JoaoHMachado/Wine_Quality_Dataset

Introdução e Problema	3
Objetivo	3
Contexto: o problema da avaliação sensorial	3
Base de dados e definição da variável alvo	3
Abordagem metodológica	4
Metodologia	5
Preparação dos dados	5
EDA	5
Escolha de modelos e tratamento do desbalanceamento	5
Validação cruzada e otimização de hiperparâmetros	6
Baseline e métricas de avaliação	6
Limitações	6
Análise e Insights	7
Análise Exploratória de Dados (EDA)	7
Insights e Implicações para a Modelagem	8
Modelos, resultados e comparação	10
Gráfico comparativo:	11
Matrizes de confusão:	11
Escolha do modelo de referência:	12
Interpretação, negócio e encerramento	13

Introdução e Problema

Objetivo

Este relatório apresenta o desenvolvimento e a comparação de três modelos de Machine Learning capazes de prever a qualidade de um vinho a partir de suas características físico-químicas. O trabalho busca demonstrar se dados mensuráveis durante a produção são capazes de apoiar, com precisão e escalabilidade, parte do julgamento subjetivo dos painéis de especialistas, gerando valor operacional para produtores e enólogos.

Contexto: o problema da avaliação sensorial


A avaliação da qualidade de vinhos é realizada por painéis de avaliadores treinados, geralmente enólogos e especialistas certificados em análise sensorial que julgam aroma, sabor, acidez e equilíbrio de cada amostra. O processo é eficaz, mas carrega quatro limitações operacionais relevantes: subjetividade (dois especialistas podem atribuir notas diferentes ao mesmo vinho); custo (painéis profissionais são caros e difíceis de manter em escala); velocidade (uma avaliação completa pode levar dias, criando gargalos em linhas de produção ativas); e escala (grandes produtores avaliam milhares de amostras por safra, tornando a análise humana inviável para cada lote).

Durante a vinificação, medidas como teor alcoólico, acidez e pH são coletadas de forma automática e objetiva. Os dados deste projeto indicam que existe uma relação quantificável entre essas medidas e a nota do especialista, abrindo caminho para a triagem automatizada de lotes, o ajuste do processo produtivo em tempo real e uma ferramenta de apoio à decisão que não depende da disponibilidade ou do estado de um degustador.

Base de dados e definição da variável alvo

O dataset utilizado foi o *Wine Quality Dataset* (WineQT). Ele contém 1.143 amostras de Vinho Verde, um tipo de vinho de origem portuguesa. Cada vinho é descrito por 11 variáveis físico-químicas (acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre e total, densidade, pH, sulfatos e teor alcoólico) e uma nota de qualidade atribuída por um painel de especialistas em escala de 0 a 10. Para viabilizar a modelagem, foi criada uma coluna adicional de classificação binária (*QualityBinary*), mantendo a nota original intacta, que agrupa os vinhos em duas categorias para tornar a previsão mais direta e aplicável.

Alta Qualidade nota ≥ 7 159 amostras • 13,9%
Baixa / Média Qualidade nota < 7 984 amostras • 86,1%



O forte desbalanceamento entre as classes (86% contra 14%) é o principal desafio do projeto. Um modelo que simplesmente previsse "baixa qualidade" para todo vinho acertaria 86% dos casos sem identificar um único vinho bom. Por isso, além da acurácia geral, o trabalho foi avaliado por três medidas complementares: o F1-score, que indica se o modelo acerta quando aponta um vinho bom e não deixa os bons escaparem; o ROC-AUC, que mede o quanto o modelo consegue separar vinhos bons dos comuns (em 90% das comparações diretas, ele aposta no certo); e o PR-AUC, que avalia a eficiência em encontrar os poucos vinhos premium dentro de um lote misto (os modelos chegaram a ser 5 vezes mais precisos do que uma escolha aleatória).

Abordagem metodológica

O grupo desenvolveu uma análise completa estruturada em etapas sequenciais, da preparação dos dados à interpretação dos resultados. A análise exploratória investigou a distribuição das variáveis, as correlações com qualidade e o impacto do desbalanceamento. O pré-processamento incluiu tratamento de valores extremos e divisão dos dados, com 80% para treinamento dos modelos e 20% para teste final, mantendo a proporção de vinhos bons e comuns em cada parte. Na etapa de modelagem, três algoritmos com abordagens distintas foram comparados: KNN (baseado em proximidade entre amostras), Random Forest (combinação de múltiplas árvores de decisão) e XGBoost (aprendizado sequencial por correção de erros).

A validação garantiu que os resultados não dependessem da sorte de um único corte dos dados, testando cada modelo cinco vezes em recortes diferentes da base com busca sistemática pelos melhores parâmetros. Por fim, a interpretação identificou quais variáveis mais influenciam a qualidade e o que isso sugere para o processo produtivo.

Metodologia

Para a solução do problema proposto, foi adotado um plano de trabalho em sete etapas: (i) preparação e limpeza da base, (ii) análise exploratória de dados (EDA), (iii) transformação da variável alvo em classificação binária, (iv) divisão estratificada em treino e teste, (v) treinamento de três modelos distintos, (vi) otimização de hiperparâmetros com validação cruzada e (vii) avaliação final no conjunto de teste, reservado exclusivamente para essa etapa.

Preparação dos dados

A base foi verificada quanto a registros duplicados e valores faltantes, não sendo identificada nenhuma inconsistência. Foi criado o atributo `qualityBinary`, uma versão binarizada do atributo `quality`, e a coluna `Id` foi removida do conjunto. Em cada modelo, a base foi dividida em 80% para treino e 20% para teste, com estratificação pela variável alvo. A estratificação garante que a proporção de vinhos de alta qualidade (~14%) seja preservada nos dois conjuntos, evitando que o teste seja mais "fácil" ou mais "difícil" que a realidade por puro acaso.

EDA

A análise exploratória verificou a distribuição de atributos e notas através de estatísticas descritivas e histogramas, o balanceamento das classes após a binarização da qualidade, estudou a correlação entre as variáveis e o atributo alvo através de um mapa de calor e detectou outliers por meio de boxplots. As descobertas dessa etapa foram essenciais e balizaram as decisões tomadas durante o projeto.

Escolha de modelos e tratamento do desbalanceamento

Foram treinados e avaliados três modelos, de modo a evitar a possibilidade de vieses resultantes de uma escolha final rápida. Os modelos selecionados foram: KNN, Random Forest e XGBoost. A escolha baseou-se nas principais características dos três, buscando ter uma visão ampla e encontrar o modelo mais eficiente e adequado à base de dados. Além das métricas de desempenho, os modelos foram comparados em critérios práticos de adoção.

O KNN se destaca pela rapidez de treinamento, que é praticamente instantâneo, e pela facilidade de implementação, com poucos hiperparâmetros; em contrapartida, exige pré-processamento cuidadoso (escalonamento e tratamento de outliers), predições lentas (cada uma recalcula distâncias para toda a base) e apresentou o menor desempenho discriminativo entre os três, necessitando muitos ajustes até ter um bom resultado.

O Random Forest oferece o perfil mais equilibrado: forte desempenho, pouco pré-processamento exigido e boa escalabilidade, com treinamento e predição em velocidades intermediárias, pecando apenas na rapidez de predição em relação ao

XGBoost. O XGBoost lidera em desempenho e em escalabilidade, com a predição mais rápida dos três, mas cobra o preço em complexidade: é o mais sensível à calibração de hiperparâmetros e o de implementação menos direta, além de treinamento mais demorado. Na soma dos critérios, o Random Forest reuniu a combinação mais favorável para o contexto do projeto.

Para adequar os modelos ao desbalanceamento dos dados, aplicou-se ponderação de classes no XGBoost (`scale_pos_weight = 6,2`) e no Random Forest (`class_weight = 'balanced'`). No KNN, não existe ponderação nativa, mas foi tratado no limiar de decisão (`threshold`). Como o KNN é sensível à escala das variáveis, aplicamos escalonamento, já o Random Forest e o XGBoost dispensaram essa etapa.

Validação cruzada e otimização de hiperparâmetros

Avaliar o modelo em um único split produz métricas dependentes da sorte do sorteio: nos experimentos, o Random Forest sem ajuste atingiu F1 de 0,63 em um split específico, mas apenas $0,545 \pm 0,078$ na validação cruzada. Por isso, toda a seleção de hiperparâmetros foi feita com Grid Search sobre validação cruzada estratificada de 5 folds, otimizando o F1 da classe minoritária. Para o KNN, que é sensível a outliers, realizou-se ainda a winsorização, por percentil e por IQR, com limites calculados exclusivamente no treino e aplicados ao teste, evitando vazamento de informação.

Baseline e métricas de avaliação

Convencionou-se o uso do Dummy Classifier, que sempre prevê a classe majoritária, como classificador baseline. Na base de dados utilizada, isso significa que ele obteria 86% de acurácia e F1 zero. Esse contraste justifica a escolha das métricas: além da acurácia, reportamos precision, recall e F1 da classe de alta qualidade, além de ROC-AUC e PR-AUC, sendo que estas últimas medem a capacidade do modelo de ordenar corretamente os vinhos por probabilidade de qualidade, independentemente do limiar de decisão.

Limitações

Por fim, cabe registrar três limitações inerentes ao desenho adotado: a base utilizada restringe-se a vinhos de um dataset desbalanceado e de um tipo específico de vinho, o que limita o aprendizado sobre ela e a generalização dos resultados; a variável-alvo reproduz notas atribuídas por um painel de especialistas e, portanto, carrega a subjetividade desse julgamento. As implicações dessas limitações para o uso do modelo são discutidas na conclusão.


Análise e Insights


A etapa inicial do projeto consistiu na compreensão da estrutura e distribuição dos dados fornecidos. A análise foi dividida em duas frentes: a exploração visual das variáveis (EDA) e o levantamento de insights para direcionar as etapas de pré-processamento e modelagem.

Análise Exploratória de Dados (EDA)

O primeiro passo da análise foi verificar a proporção das classes na base de dados, considerando a transformação da variável de qualidade em uma classificação binária, em que notas maiores ou iguais a 7 receberam o valor 1, e notas menores que 7 receberam o valor 0.


Foi verificado um cenário de forte desbalanceamento: aproximadamente 86,1% da base (984 amostras) corresponde a vinhos de baixa ou média qualidade, enquanto apenas 13,9% (159 amostras) são classificados como vinhos de alta qualidade. Na sequência, foi calculada a matriz de correlação para identificar a relação estatística entre as características físico-químicas dos vinhos e a variáveis de qualidade.





O mapa de calor demonstra que o teor alcoólico (alcohol) apresenta a maior correlação positiva com a qualidade do vinho (0,48), indicando que maiores concentrações de álcool estão associadas a avaliações superiores. Em contrapartida, a acidez volátil (volatile acidity) possui a maior correlação negativa (-0,41), evidenciando seu impacto prejudicial à percepção de qualidade por parte dos especialistas. Fatores como sulfatos (0,26) e ácido cítrico (0,24) apresentam correlações positivas moderadas, auxiliando na conservação e no frescor da bebida.

Devido à forte relevância do teor alcoólico evidenciada na matriz, seu comportamento foi analisado de forma isolada por meio de um boxplot, permitindo comparar as distribuições estatísticas entre as duas categorias de vinho.



A visualização confirma que as amostras de alta qualidade (classe 1) apresentam uma concentração de teor alcoólico visivelmente superior à dos vinhos de baixa ou média qualidade (classe 0). Enquanto a mediana dos vinhos comuns gravita em torno de 10%, a mediana dos vinhos premium ultrapassa os 11,5%, reforçando o álcool como um forte atributo discriminador para a classificação final do modelo preditivo.

Insights e Implicações para a Modelagem

O impacto do desbalanceamento na avaliação: A discrepância entre as classes (86% contra 14%) indicou que o uso isolado da acurácia seria insuficiente para avaliar os modelos. Um classificador que previsse apenas a classe majoritária alcançaria 86% de acerto sem identificar um único vinho de alta qualidade. Por isso, definiu-se a necessidade de utilizar validação cruzada estratificada e focar em métricas complementares e mais precisas para a classe minoritária, como o F1-Score e o ROC-AUC

A influência das propriedades físico-químicas: Os dados demonstram que características mensuráveis durante a produção possuem relação direta com a nota final dos especialistas. Vinhos com maior teor alcoólico tendem a ser melhor avaliados. Em contrapartida, a acidez volátil prejudica a avaliação sensorial, uma vez que em níveis altos confere odores e gostos indesejados, semelhantes a vinagre. Outros fatores, como sulfatos e ácido cítrico, auxiliam na estabilidade, conservação e no frescor da bebida.

A presença de valores extremos e a escolha dos algoritmos: A visualização das distribuições revelou a presença de outliers (valores atípicos) em variáveis como cloretos e dióxido de enxofre. Esse achado indicou que modelos sensíveis à escala e baseados em distância, como o KNN, exigiriam técnicas de tratamento de dados (como a winsorização), enquanto algoritmos baseados em árvores, como Random Forest e XGBoost, seriam naturalmente mais resilientes a essas distorções estatísticas.

Modelos, resultados e comparação

Modelo	Acurácia	Precision (Classe 1)	Recall (Classe 1)	F1 (Classe 1)	ROC-AUC	PR-AUC
Dummy (baseline)	0,860	0,000	0,000	0,000	0,500	0,140
KNN (Grid Search, IQR)	0,886	0,588	0,625	0,606	0,853	0,522
XGBoost (Grid Search)	0,882	0,571	0,625	0,597	0,911	0,691
Random Forest (Grid Search)	0,891	0,630	0,531	0,576	0,922	0,694


Os três modelos foram avaliados sob condições idênticas: mesmo conjunto de teste (229 vinhos, 20% da base), mesma semente de divisão (`random_state = 38`) e estratificação por `qualityBinary`, o que preservou no teste a proporção original de 86% de vinhos comuns e 14% de alta qualidade. Essa padronização é o que torna a comparação justa: qualquer diferença de desempenho vem dos algoritmos e de seus ajustes, e não do sorteio dos dados.

O baseline Dummy funciona como régua mínima. Ao prever sempre "vinho comum", ele acerta 86% das vezes apenas por efeito do desbalanceamento, mas sua precision, recall e F1 na classe de interesse são iguais a zero. Em outras palavras, ele não encontra um único vinho bom. Os três modelos superam esse piso em todas as métricas da classe minoritária, o que confirma que existe sinal real nas variáveis físico-químicas.

Na comparação entre si, os modelos ficam próximos em acurácia (88,2% a 89,1%) e em F1 (0,576 a 0,606), mas a tabela revela a troca central entre Random Forest e XGBoost. O primeiro tem a maior precision (0,630): quando aponta um vinho como de alta qualidade, acerta mais. O segundo tem o maior recall (0,625, empatado com o KNN): encontra mais vinhos bons. Os AUCs reforçam a vantagem das duas árvores sobre o KNN, com ROC-AUC de 0,922 (Random Forest) e 0,911 (XGBoost) contra 0,853, e PR-AUC de 0,694 e 0,691 contra 0,522. O PR-AUC, aliás, é a métrica mais exigente em bases desbalanceadas, pois avalia a qualidade do ranking justamente na classe rara. A decisão entre precision e recall aparece na escolha do modelo de referência, mais adiante.


Nota metodológica: acurácia, precision, recall e F1 dos três modelos, assim como o ROC-AUC e o PR-AUC de XGBoost e Random Forest, vêm diretamente do notebook. O ROC-AUC e o PR-AUC do KNN e do Dummy não estavam impressos no notebook original e foram calculados reproduzindo o mesmo pipeline. A acurácia e o F1 obtidos nessa reprodução bateram exatamente com os valores originais, o que valida os dois números novos.

Gráfico comparativo:



O gráfico de barras consolida as seis métricas dos três modelos e do baseline. A leitura principal está no contraste entre dois grupos de métricas. Na acurácia, até o Dummy parece competitivo, com 86% contra cerca de 89% dos modelos, e isso mostra visualmente por que essa métrica não pode servir de critério em bases desbalanceadas. Já no F1, no ROC-AUC e no PR-AUC, o Dummy cai para zero ou quase isso, e a diferença real entre os modelos aparece: XGBoost e Random Forest ficam claramente à frente do KNN nas métricas de ranking, enquanto os três permanecem próximos no F1.

Matrizes de confusão:



Dos 229 vinhos de teste, 197 são comuns e 32 são de alta qualidade, e os erros dos modelos se distribuem de forma complementar. O Random Forest é o mais conservador ao conceder o selo: classificou apenas 27 vinhos como "alta qualidade", acertando 17 e errando 10, o menor número de falsos positivos entre os três. A contrapartida é que deixou escapar 15 dos 32 vinhos bons, o maior número de falsos negativos. XGBoost e KNN adotam o comportamento oposto: aprovam com mais generosidade, encontrando 20 dos 32 vinhos bons (apenas 12 perdidos), mas pagam por isso com mais falsos positivos, 15 e 14 respectivamente. Dito de forma simples, o Random Forest erra por omissão, enquanto XGBoost e KNN erram por excesso. Como nenhum modelo


minimiza os dois tipos de erro ao mesmo tempo, a escolha entre eles depende de qual erro custa mais caro para o negócio, e não de qual "venceu" no placar geral.

Escolha do modelo de referência:

O modelo de referência é o Random Forest, por três razões combinadas. Primeiro, ele lidera nas métricas de capacidade discriminativa, com o maior ROC-AUC (0,922) e o maior PR-AUC (0,694), o que indica a melhor separação entre as classes no conjunto. Segundo, tem a maior precision da classe de interesse (0,630), ou seja, é o modelo em que o selo "alta qualidade" é mais confiável, algo relevante quando esse selo tem peso comercial, já que prometer uma qualidade que o vinho não entrega custa reputação. Terceiro, seu F1 (0,576) fica apenas 0,03 abaixo do melhor valor, uma diferença marginal diante da vantagem nos demais critérios. Vale registrar a condição de troca: se o modelo for usado como pré-triagem para degustação, um cenário em que perder um vinho bom custa mais do que analisar um falso candidato a mais, o XGBoost passa a ser a escolha adequada, pois tem o maior recall e encontra 20 dos 32 vinhos bons. A recomendação, portanto, não é absoluta: depende do custo relativo de cada erro no uso pretendido.

Interpretação, negócio e encerramento

Os três modelos, apesar de usarem algoritmos completamente diferentes, chegaram ao mesmo lugar. Álcool, acidez volátil, sulfatos e ácido cítrico apareceram como as variáveis decisivas em todos eles. Isso não surpreende. A análise exploratória já havia apontado nessa direção. O que isso significa na prática é que a correlação observada na etapa inicial tinha fundamento sólido. E dá ao resultado uma leitura enológica que faz sentido. O álcool reflete a maturação da uva. A acidez volátil sinaliza defeitos de processo. Sulfatos e ácido cítrico se ligam à conservação e ao equilíbrio do paladar. Já cloretos e densidade ficaram para trás, com influência marginal nos três casos.



Do ponto de vista técnico, o trabalho demonstrou que a qualidade do resultado depende muito do rigor técnico. Os três modelos ficaram próximos nas métricas finais (F1 entre 0,576 e 0,606), e o que os separou de uma avaliação ingênua foi o tratamento dado ao problema: validação cruzada estratificada em vez de um único split (que superestimou o F1 do Random Forest em 0,63 contra 0,545 reais), otimização de hiperparâmetros via grid search, tratamento explícito do desbalanceamento em cada modelo e métricas adequadas à classe minoritária, uma vez que um classificador trivial alcançaria 86% sem identificar um único vinho bom.

A escolha final do Random Forest foi técnica e também de negócio. O modelo liderou em ROC-AUC (0,922) e PR-AUC (0,694), F1 equivalente ao XGBoost e o menor número de falsos positivos (10 em 229 testes). O Random Forest é o modelo mais confiável quando o custo de prometer qualidade que o vinho não tem é alto, como em seleção para rótulo premium, exportação, ou concursos/competições. O XGBoost deve ser documentado como alternativa quando o custo de perder um vinho bom superar o de um falso positivo.

As limitações anunciadas na metodologia têm consequências diretas sobre o que se pode concluir. A base, restrita a vinhos de um único dataset público, impede generalizar o modelo para outros estilos ou regiões sem recalibração. A variável-alvo reproduz notas de um painel de especialistas, de modo que o modelo padroniza um julgamento

subjetivo. A escassez de exemplos positivos (159 vinhos, 13,9%) impõe um teto ao aprendizado sobre a classe de interesse, o que se reflete nos valores modestos de F1 e reforça o papel do modelo como ferramenta de triagem e apoio, não de decisão final.

Como próximos passos e recomendações práticas, destacam-se quatro ações fundamentais: controlar a acidez volátil durante a fermentação e maturação, tratando desvios antes do engarrafamento (por ser o fator negativo mais forte da base); acompanhar o teor alcoólico como indicador de maturação da uva na colheita (dado que vinhos acima de 11,5% têm 46% de chance de serem premium), sem usá-lo como parâmetro a ser corrigido depois; implementar uma triagem automatizada para priorizar a degustação dos lotes que o modelo aponta como promissores, reduzindo o volume de amostras analisadas pelo painel humano; e reconhecer os limites da base atual, utilizando o modelo como apoio à decisão do enólogo, e não como substituto, ampliando a base antes de escalar.

Em síntese, o projeto atingiu seu objetivo: medidas físico-químicas coletadas na produção carregam informação suficiente para prever a avaliação de especialistas com desempenho consistente (89% de acurácia e ROC-AUC de 0,92, contra 86% de um palpite trivial), e o caminho metodológico adotado mostrou-se tão determinante para o resultado quanto os próprios algoritmos.